InnoDB 事务/锁/多版本分析

网易杭研-何登成

个人简介

- 姓名：何登成
- 工作：
  - 就职于杭州网易研究院，进行自主研发的TNT存储引擎的架构设计/研发工作
- 联系方式
  - 邮箱：he.dengcheng@gmail.com
  - 微博：何_登成
  - 主页：http://hedengcheng.com/

InnoDB存储引擎

- 模块划分
  - OS层
  - 锁
  - 事务
  - 多版本
  - 日志/恢复
  - 索引
    - 列/行/页面/Extent/Segment/Tablespace/File
  - Buffer Pool
  - Handler层
  - ...

大纲

- InnoDB事务
  - 事务结构/功能
  - XA事务/Group Commit
  - mini-transaction
- InnoDB锁
  - 锁结构/类型/功能
  - 锁等待/死锁检测
  - 自增序列锁(autoinc lock)
  - 半一致读(semi-consistent read)
  - 隐式锁(implicit lock)
- InnoDB多版本
  - ReadView
  - 聚簇索引/二级索引
  - 快照读
  - Index Only Scan
  - RC vs RR
  - Purge
- InnoDB事务/锁/多版本总结

InnoDB事务/锁/多版本

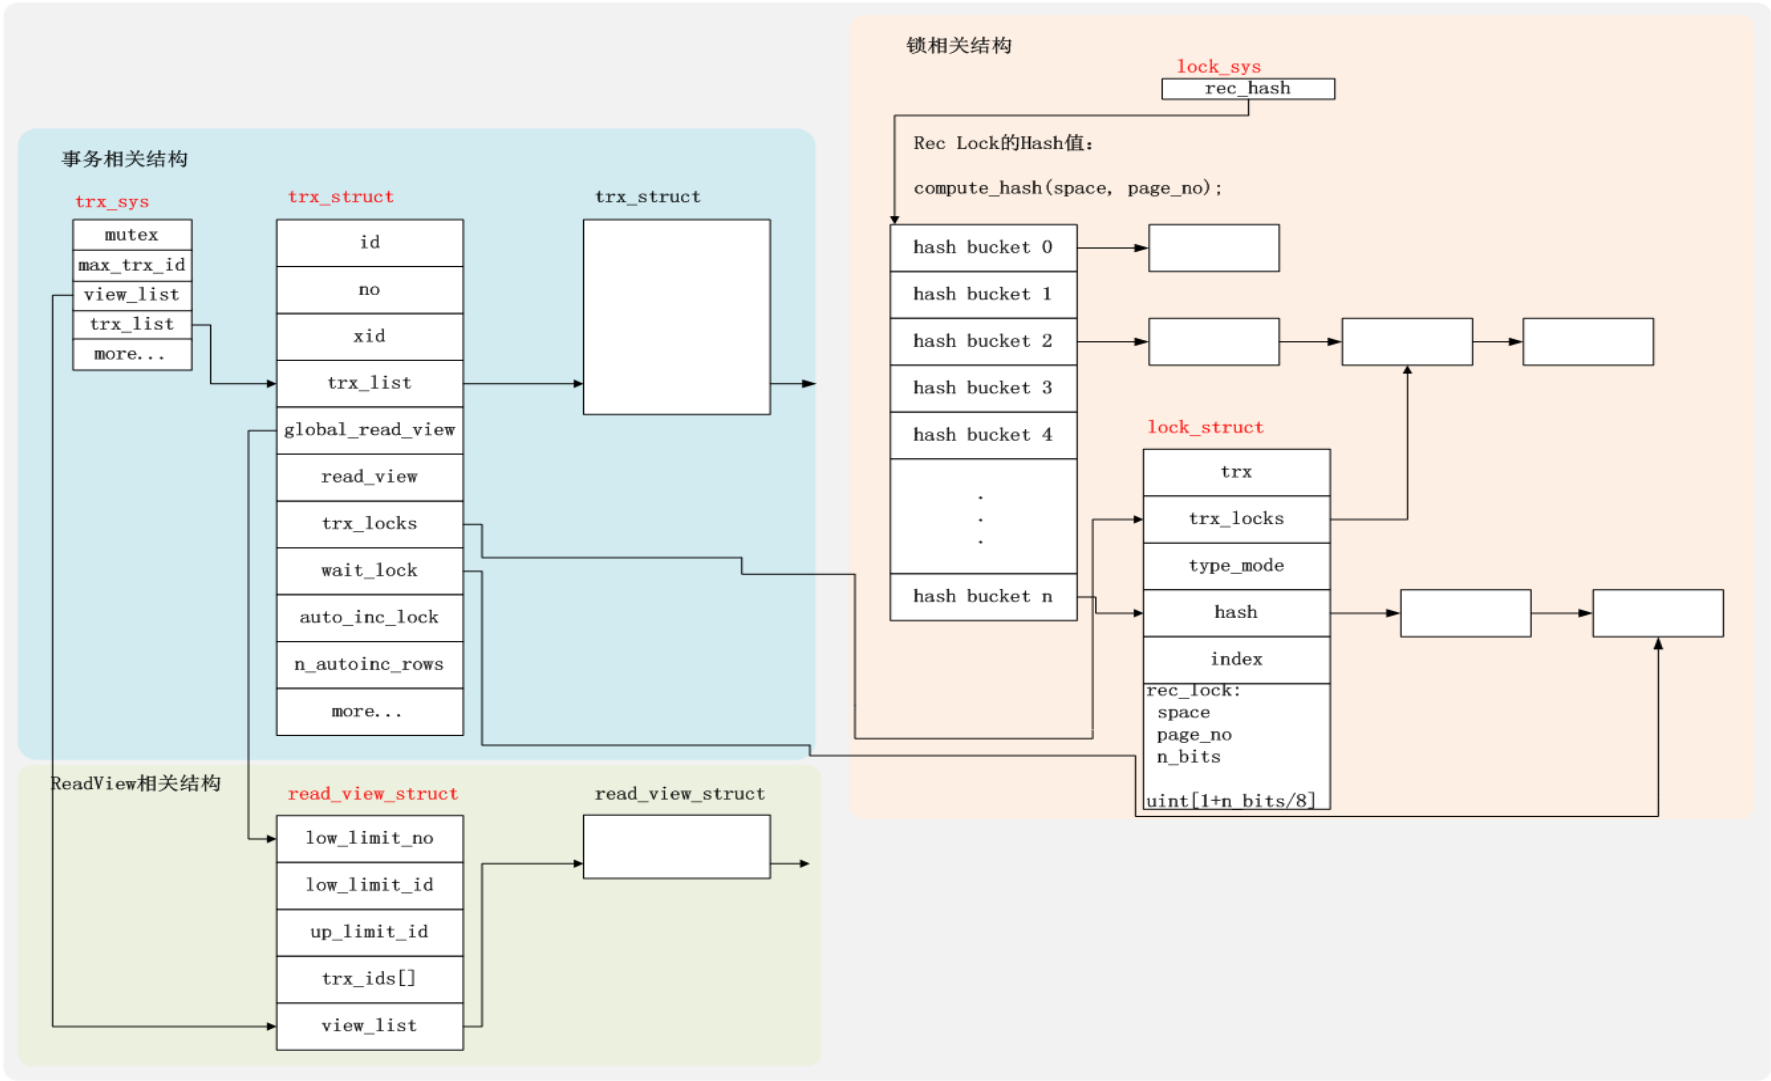

InnoDB事务-结构

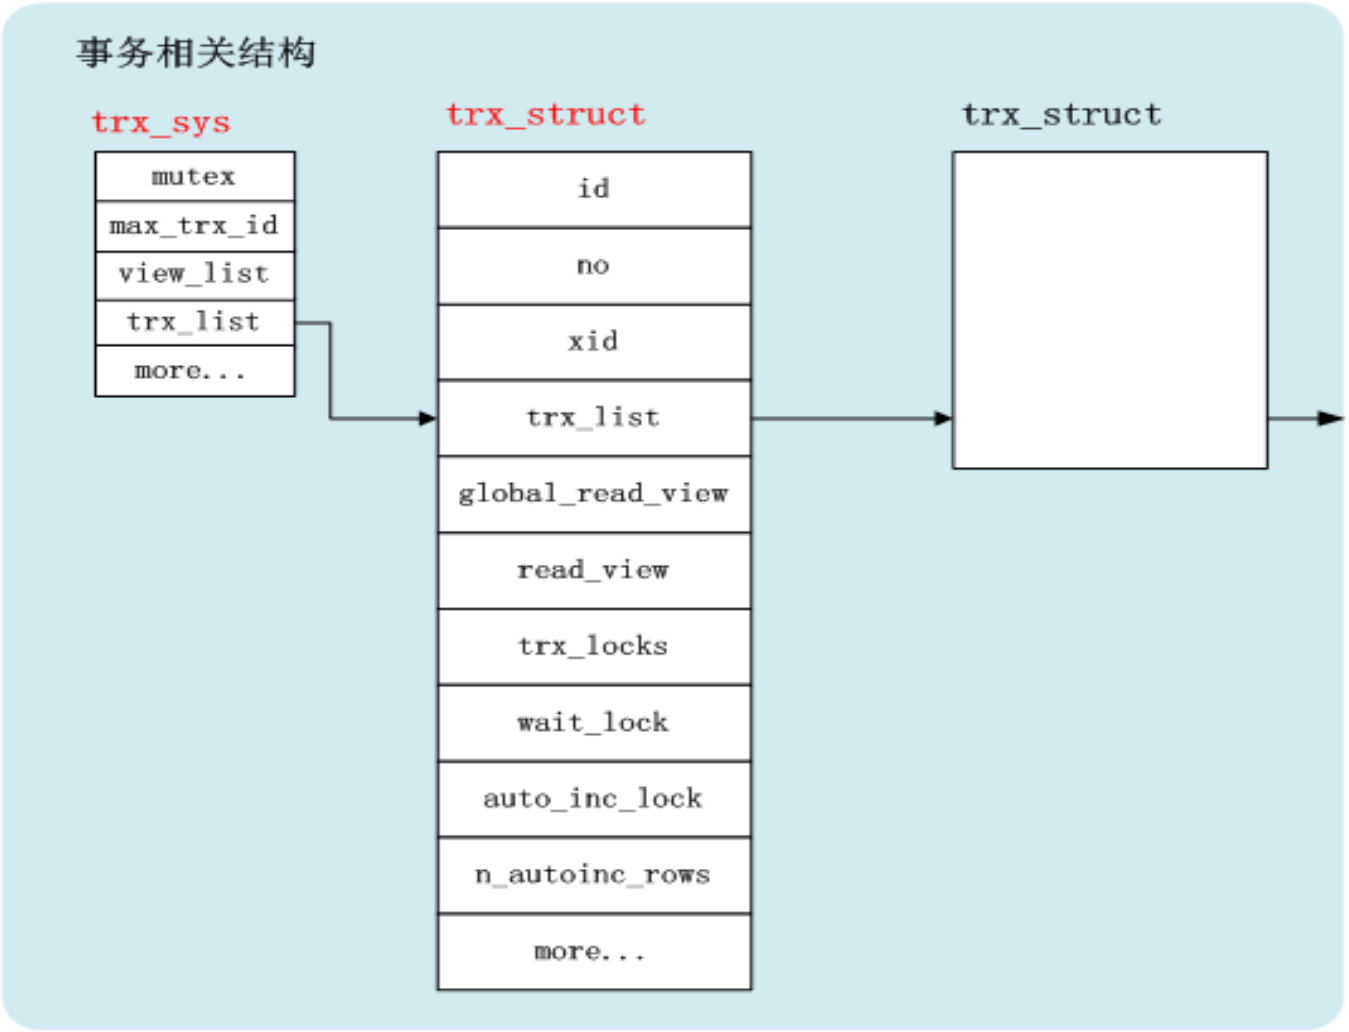
事务相关结构
trx_sys
mutex
max_trx_id
view_list
trx_list
more...
trx_struct
id
no
xid
trx_list
global_read_view
read_view
trx_locks
wait_lock
auto_inc_lock
n_autoinc_rows
more...
trx_struct

InnoDB事务-结构(cont.)

- trx_sys(全局唯一)
  - mutex：　critical section，控制事务的分配/提交/回滚
  - max_trx_id：　当前系统最大的事务号
分配256次，写一次文件，持久化
  - trx_list：　系统当前所有活跃事务链表
  - view_list：　系统当前所有ReadView链表

- trx_struct(事务对象)
  - id/no：　事务号，标识事务起始/提交顺序
    - id用户可见，no用户不可见；共用trx_sys的max_trx_id进行分配
  - xid：　XA事务标识
  - (global)read_view:　事务所属的ReadView
  - trx_locks：　事务持有的所有lock(表锁/记录锁/Autoinc锁)
  - wait_lock：　事务当前正在等待的lock

InnoDB事务-功能

- 快照读
  - 创建ReadView，实现RC/RR隔离级别(MVCC时分析)
- 当前读
  - 对表/记录加锁
  - 同一事务，所有的锁，链成链表
- I/U/D
  - 加锁
  - 记录undo日志/redo日志
- 数据持久化
  - 事务commit
    - 需要哪些操作？
- 数据回滚
  - 事务rollback
    - 需要哪些操作？

InnoDB事务-XA事务

- Why XA？
  - 为了保证InnoDB redo log与MySQL binlog的一致性
  - backup
- XA Commit流程
  - InnoDB prepare -> Binlog commit -> InnoDB commit
  - Binlog作为事务协调器
    - Transaction Coordinator
  - 参数
    - MySQL： sync_binlog
    - InnoDB：innodb_flush_log_at_trx_commit
- Group Commit
  - MariaDB/Percona 5.5.19-rel24/MySQL 5.6

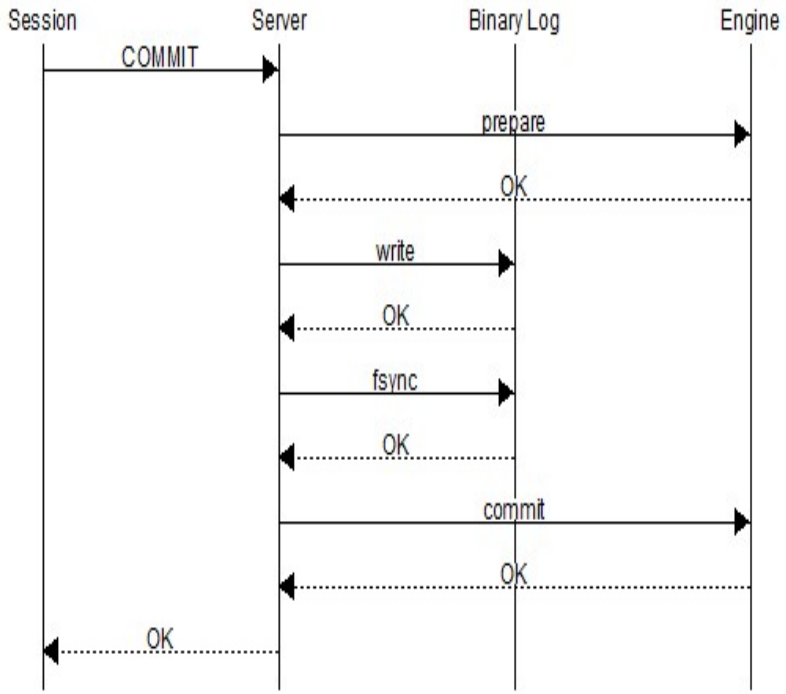

InnoDB事务-mini-transaction

- mini-transaction(微事务)
  - 定义
    - mini-transaction不属于事务；InnoDB内部使用
    - 对于InnoDB内所有page的访问(I/U/D/S)，都需要mini-transaction支持
  - 功能
    - 访问page，对page加latch (*只读访问：S latch；写访问：X latch*)
    - 修改page，写redo日志 (*mtr本地缓存*)
    - page操作结束，提交mini-transaction (*非事务提交*)
      - 将redo日志写入log buffer
      - 将脏页加入Flush List链表
      - 释放页面上的 S/X latch
  - 总结
    - mini-transaction，保证单page操作的原子性(读/写单一page)
    - mini-transaction，保证多pages操作的原子性(索引SMO/记录链出，多pages访问的原子性)

InnoDB事务/锁/多版本

- InnoDB事务
  - 事务结构/功能
  - XA事务
  - mini-transaction
- InnoDB锁
  - 锁结构/类型/功能
  - 锁等待/死锁检测
  - 自增序列锁
  - 半一致读
  - 隐式锁
- InnoDB多版本
  - ReadView
  - 聚簇索引/二级索引
  - 快照读
  - Index Only Scan
  - RC vs RR
  - Purge
- InnoDB事务/锁/多版本总结

InnoDB锁-定义

- 数据库中常用锁类型(Lock/Latch/Mutex)
  - 相同
    - 都是用来锁住一个资源
  - 不同
    - Lock (事务锁)
      - 实现复杂；功能多样；可大量/长时间持有
      - 支持死锁检测
      - 用途：锁用户记录/表
    - Latch (页面锁)
      - 实现相对简单；功能相对简单；少量/短时间持有
      - 不支持死锁检测
      - 用途：Latch page，防止访问时页面被修改/替换(pin)
    - Mutex (临界区锁)
      - 最为简单(CAS, TAS); 功能简单；极短持有时间
      - 无死锁检测
      - 用途：保护critical section(临界区)

InnoDB锁-结构

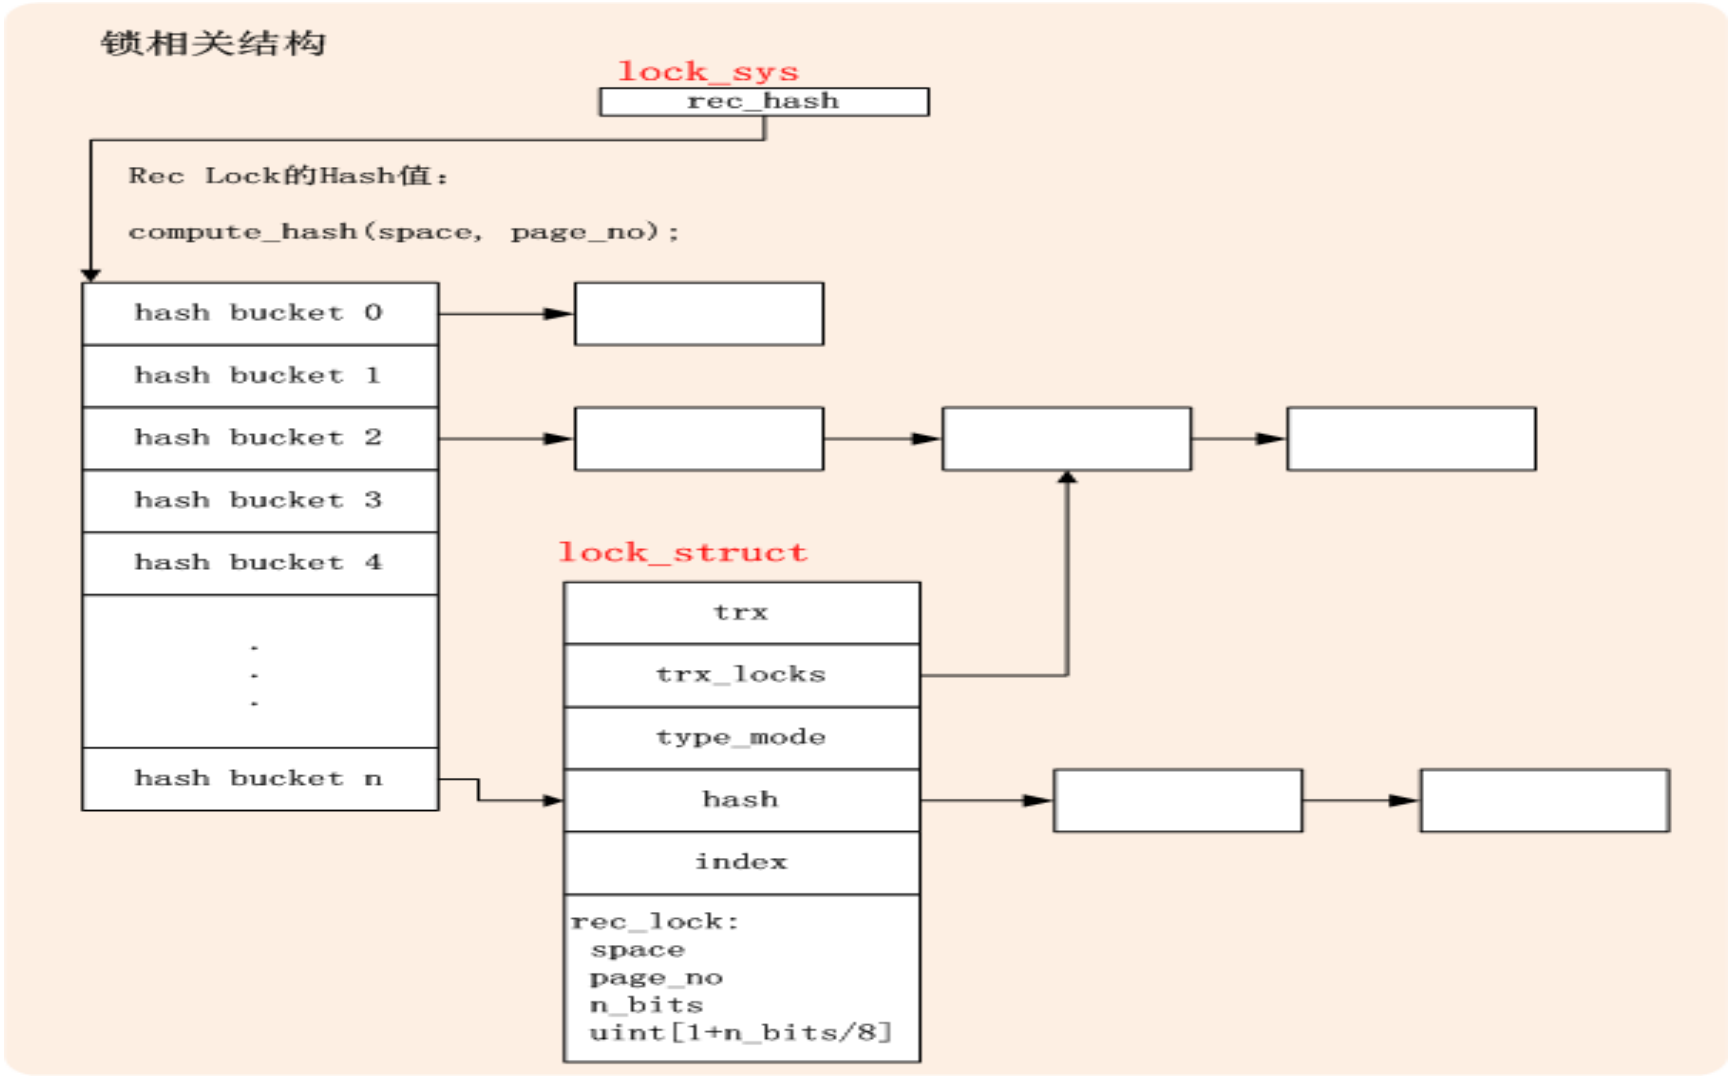
锁相关结构
lock_sys
rec_hash
Rec Lock的Hash值：
compute_hash(space, page_no);
hash bucket 0
hash bucket 1
hash bucket 2
hash bucket 3
hash bucket 4
hash bucket n
lock_struct
trx
trx_locks
type_mode
hash
index
rec_lock:
space
page_no
n_bits
uint[1+n_bits/8]

InnoDB锁-结构(cont.)

- lock_sys(Rec lock hash)
  - InnoDB的行锁，通过hash表管理
  - hash值，通过[space, page_no]计算：同一页面在同一hash bucket中
  - *思考：表锁呢？*

- lock_struct
  - trx_locks：　　属于同一事务的锁链表
  - type_mode：　　加锁模式
    - *一个锁对象，一个加锁模式*
  - hash：　　记录锁在hash表中的指针
  - index：　　锁对应的索引
  - rec_lock/tab_lock: 以上属于表锁/行锁共用结构，此处为不同结构

InnoDB锁-结构(cont.)

- lock_rec_struct
  - InnoDB行锁特殊结构
  - InnoDB行锁实例，对应于一个索引页面中的所有记录

```
n_bits = page_dir_get_n_heap(page) + LOCK_PAGE_BITMAP_MARGIN;
n_bytes = 1 + n_bits / 8;
lock = mem_heap_alloc(trx->lock_heap, sizeof(lock_t) + n_bytes);
```

  - 行锁实例的最后，是n_bytes的bitmap
    - bitmap的下标对应于page中的heap_no(记录唯一)
    - bitmap=1，heap_no记录加锁

InnoDB锁-行锁

- 行锁
  - 行锁实例
    - 对应 Index Page (聚簇 & 非聚簇)
  - 行锁标识
    - 记录在page中的heap_no
  - heap_no
    - **记录插入page，分配**
    - 删除记录重用，heap_no可重用
    - heap_no与slot_no不同
    - **heap_no不可用来查找记录**
  - 行锁实例(右图)
    - 根据查询条件，行锁实例bitmap的1，3，6 bits设置为1，对应于heap_no 1，3，6号记录

```
Table: t1(a int primary key, b int)
Insert into t1 values (1,1),(3,3),(8,8),(4,4),(2,2),(9,9),(5,5);

当前读:
Select * from t1 where a > 2 and a < 8 lock in share mode;
```

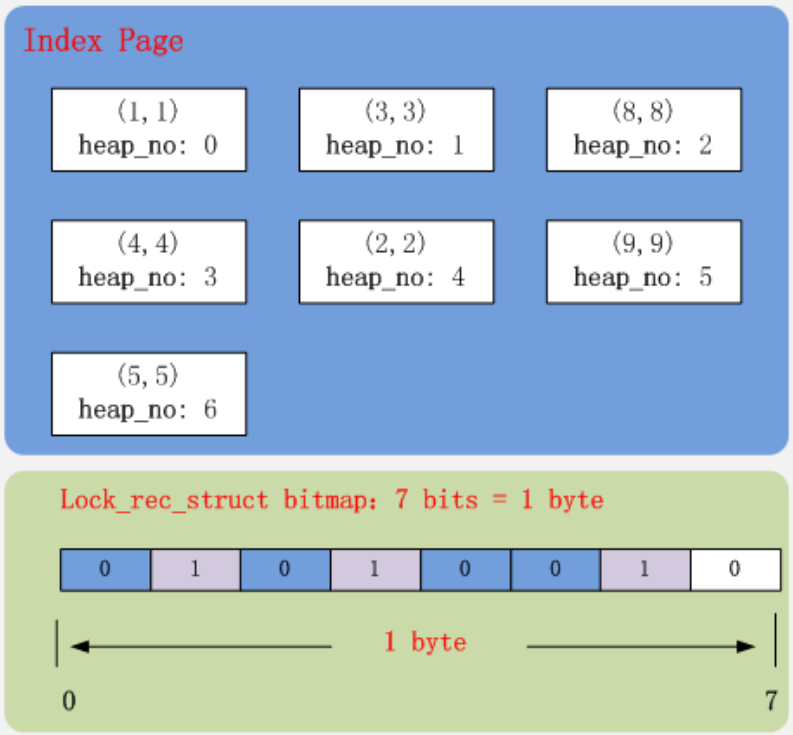

InnoDB锁-行锁开销

- 锁开销接近Oracle？

  InnoDB宣称自己的行锁代价接近于Oracle，一条记录用1 bit即可，实际情况呢？InnoDB的行锁对象，管理一个Page，行锁上的1 bit，对应Page中的一条记录。一个400条记录的Page，一个行锁对象大小约为102 bytes。

  锁一行:　　代价为102 bytes/行;
  锁400行:　　代价为102 bytes/400 = 2 bits/行。

- 实际情况
  - 锁一行代价巨大(如何优化，后续揭晓)
  - 锁一页代价较小

InnoDB锁-锁模式

- **数据锁模式**
  - 数据锁：仅仅锁住数据
  - LOCK_IS, LOCK_S, LOCK_IX, LOCK_X
  - 意向锁：LOCK_IS, LOCK_IX
    - 表级锁；加记录锁前必须先加意向锁；
    - 功能： 杜绝行锁与表锁相互等待
  - 兼容矩阵

	IS	IX	S	X
IS	+	+	+	−
IX	+	+	−	−
S	+	−	+	−
X	−	−	−	−

+: 兼容
-: 不兼容

InnoDB锁-锁模式(cont.)

- **非数据锁模式**
  - 不锁数据，标识数据前GAP的加锁情况；非数据锁与数据锁之间不冲突
  - LOCK_ORDINARY
    - next key锁，同时锁住记录(数据)，并且锁住记录前面的Gap
  - LOCK_GAP
    - Gap锁，不锁记录，仅仅记录前面的Gap
  - LOCK_NOT_GAP
    - 非Gap锁，锁数据，不锁Gap
  - LOCK_INSERT_INTENSION
    - Insert操作，若Insert的位置的下一项上已经有Gap锁，则获取insert_intension锁，等待Gap锁释放
  - LOCK_WAIT
    - 当前锁不能立即获取，需要等待

InnoDB锁-锁模式(cont.)

- **非数据锁模式**(cont.)
  - 非数据锁兼容模式

	G	I	R	N
G	+	+	+	+
I	−	+	+	−
R	+	+	−	−
N	+	+	−	−

+: 兼容; −: 不兼容
G: LOCK_GAP; I: INSERT_INTENSION;
R: NOT_GAP; N: LOCK_ORDINARY

InnoDB锁-实例分析

- Repeatable Read

```
CREATE TABLE t1 (a INT, b INT, KEY (b)) ENGINE=innodb;
INSERT INTO t1 VALUES (1,10), (2,10), (2,20), (3,30);

-- session 1                                                    -- session 2
START TRANSACTION;
SELECT * FROM t1 WHERE b=20 FOR UPDATE;

                                                                START TRANSACTION;
                                                                SELECT * FROM t1 WHERE b=10 ORDER BY A FOR UPDATE;
update t1 set b = 10 where a = 10;
                                                                SELECT * FROM t1 WHERE b=10 ORDER BY A FOR UPDATE;
-- 测试结果
-- session 1
1. session 1对b索引的(20)加锁：          LOCK_REC(32) + LOCK_X(5) + LOCK_ORDINARY(0)
2. session 1对聚簇索引的(2,20)加锁：     LOCK_REC_NOT_GAP(1024) + LOCK_REC + LOCK_X
3. session 1对b索引的(30)加锁：          LOCK_GAP(512) + LOCK_X.
4. session 1在b索引上，创建两个lock实例

-- session 2
1. b索引上的(1,10),(2,10)项，加锁：      LOCK_REC(32) + LOCK_X(5) + LOCK_ORDINARY(0)
2. b索引上的(2,20)项，加锁：             LOCK_GAP(512) + LOCK_X.
3. 聚簇索引上的(1,10),(2,10)项，加锁：   LOCK_REC_NOT_GAP(1024) + LOCK_REC + LOCK_X
4. session 2在b索引上，同样需要创建两个lock实例
5. session 2不需要等待session 1的提交，(2,20)上的锁，并不冲突
```

InnoDB锁-实例分析(cont.)

- Read Committed

```
session session transaction isolation level read committed;

-- session 1                                                    -- session 2
START TRANSACTION;
SELECT * FROM t1 WHERE b=20 FOR UPDATE;

                                                                START TRANSACTION;
                                                                SELECT * FROM t1 WHERE b=10 ORDER BY A FOR UPDATE;
update t1 set b = 10 where a = 10;
                                                                SELECT * FROM t1 WHERE b=10 ORDER BY A FOR UPDATE;
-- 测试结果
-- session 1
1. session 1对b索引的(20)加锁:          LOCK_REC_NOT_GAP(1024) + LOCK_REC(32) + LOCK_X(5)
2. session 1对聚簇索引的(2,20)加锁:     LOCK_REC_NOT_GAP(1024) + LOCK_REC + LOCK_X

-- session 2
1. b索引上的(1,10),(2,10)项，加锁:       LOCK_REC_NOT_GAP(1024) + LOCK_REC(32) + LOCK_X(5)
2. 聚簇索引上的(1,10),(2,10)项，加锁:    LOCK_REC_NOT_GAP(1024) + LOCK_REC + LOCK_X
```

InnoDB锁-加锁总结

- **Repeatable Read**

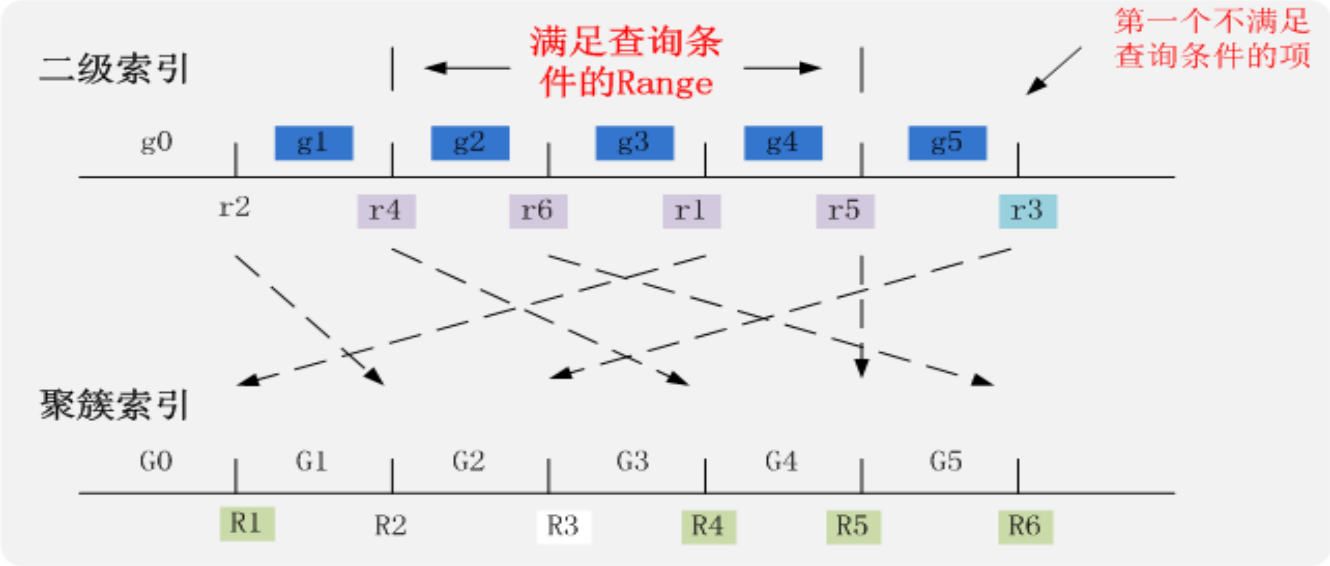

- **Access Index**
  - 满足条件的记录[r4,r6,r1,r5]，Next Key锁(LOCK_ORDINARY)
  - 第一条不满足条件的记录[r3]
    - 等值查询 -> GAP锁
    - 非等值查询 -> Next Key锁
  - GAP[g1-g5]被锁住，无法进行Insert；
  - 数据[r4,r6,r1,r5,(r3)]被锁住

- **Cluster Index**
  - 记录[R1, R4, R5, R6, (R3)]，数据锁(NO_GAP)

InnoDB锁-加锁总结(cont.)

- **Read Committed**

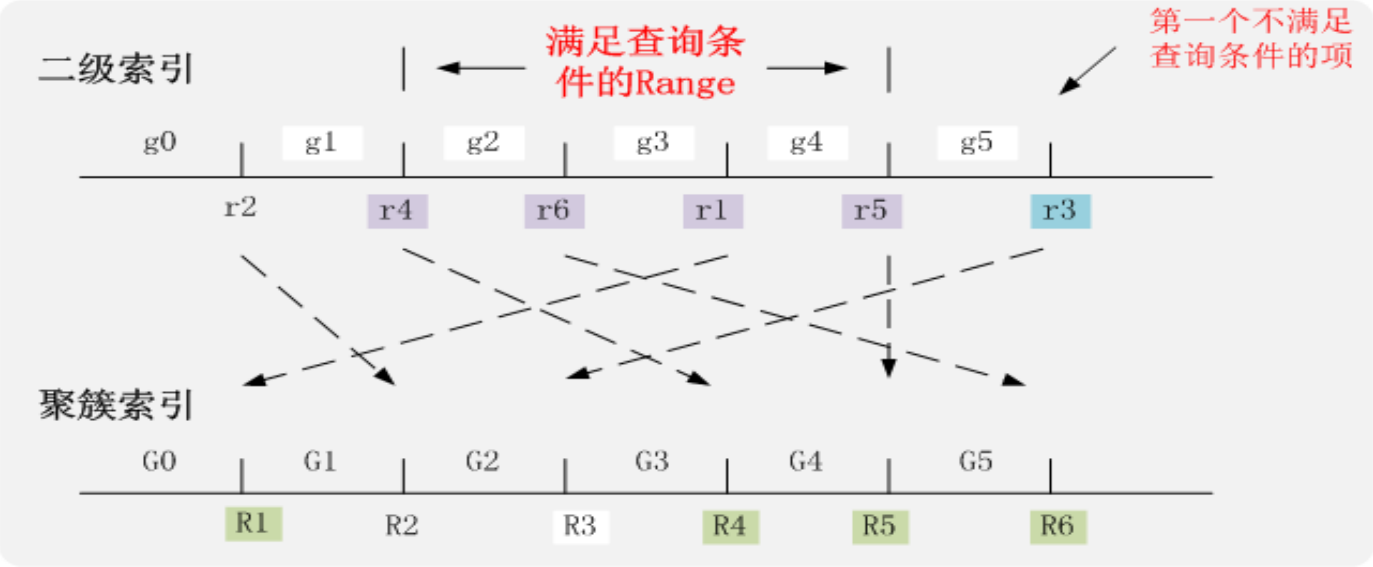

- **Access Index**
  - 满足条件的记录[r4,r6,r1,r5]，数据锁(NO_GAP)
  - 第一条不满足条件的记录[r3]
    - 等值查询 -> 无锁
    - 非等值查询 -> 数据锁
  - 锁数据，不锁GAP

- **Cluster Index**
  - 记录[R1, R4, R5, R6, (R3)]，数据锁

InnoDB锁-等待

- 加锁/锁等待

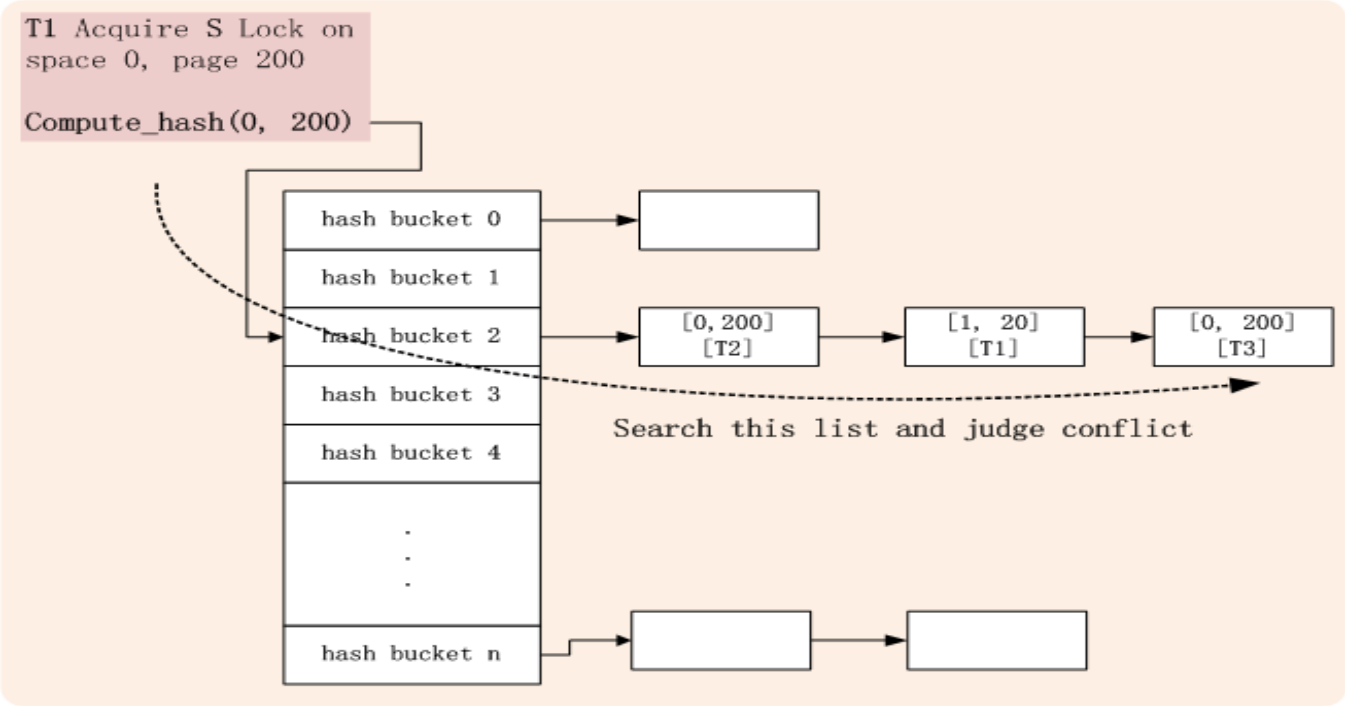

  - 遍历Hash Bucket 2链表
  - T1加锁与T2，T3冲突 -> 等待
  - T1加锁与T2，T3不冲突 -> 获取

InnoDB锁-死锁检测

- 死锁检测
  - 加锁需要等待，则触发死锁检测
  - 死锁检测由用户线程处理
  - 构造Wait-For-Graph (WFG)
  - 深度优先遍历 (递归)
    - 后续改为非递归实现(栈)
  - 死锁检测过程中，持有kernel_mutex
    - 后续MySQL版本中，新增lock_sys->mutex
  - 根据事务权重，选择牺牲者
    - 事务权重：undo日志量 + 锁数量

InnoDB锁-分裂/合并/迁移

- 锁分裂
  - 索引页面分裂 -> 锁分裂
- 锁合并
  - 索引页面合并 -> 锁合并
- 锁迁移
  - 插入记录
    - Gap锁从插入后项迁移到新插入项
  - 删除记录
    - Gap锁从删除项迁移到删除后项

InnoDB锁-唯一性约束

- 唯一性约束
  - primary(unique)索引，在insert/update时，需要进行唯一性检查，通过加锁实现
- 唯一性检查流程
  - 根据insert/update记录，构造索引项，定位页面中insert/update位置
  - 记录下insert项与插入位置前后项的相似度：n
  - n=键值数 -> 存在相同的项 -> 可能存在唯一性冲突
  - 相同项，加锁检查
    - insert/update：　　S 锁
    - on duplicate update：　　X 锁
    - 聚簇索引
      - 相同键值最多只有一项；
      - delete项：不存在唯一性冲突；非delete项：存在唯一冲突
    - 二级索引
      - 相同键值可能有多项；
      - 根据insert项，进行range scan，对range中的所有项加锁；
      - delete项：不存在唯一性冲突；非delete项：存在唯一冲突

InnoDB锁-Autoinc锁

- 自增序列锁(Autoinc Lock)
  - 功能
    - 复杂insert语句+statement binlog下，保证master-slave一致性
  - 自增序列并发控制
    - mutex：　　简单Insert/replace语句
    - Autoinc_lock：　　insert into select * from 语句
  - 参数设置
    - **innodb_autoinc_lock_mode**
      - **0，1，2**

InnoDB锁-半一致读

- Semi-Consistent Read(半一致读)
  - 目标
    - 提高系统并发性能，减少锁等待
  - 方案
    - 当前读，可读取记录历史版本
    - 不满足查询条件的记录，可提前放锁
  - 前提
    - Read Committed隔离级别
    - innodb_locks_unsafe_for_binlog

InnoDB锁-隐式锁

- Implict Lock(隐式锁)
  - 目标
    - 减少Insert时加锁开销，减少锁内存消耗
    - 降低锁一行记录的情况(*锁一行代价巨大*)
  - 方案
    - Insert时，不加锁(Implict lock)
    - 后续scan(当前读)，如果碰到Implicit lock，则转换为Explicit lock
    - 延迟加锁
  - Implicit Lock判断
    - 聚簇索引
      - 根据记录上的trx_id判断 (*trx_id是否为活跃事务？*)
    - 二级索引
      - 根据索引页面上的max_trx_id + 回聚簇索引判断 (*max_trx_id是否小于最小活跃事务？*)
      - 存在bug

InnoDB事务/锁/多版本

- InnoDB事务
  - 事务结构/功能
  - XA事务
  - mini-transaction
- InnoDB锁
  - 锁结构/类型/功能
  - 锁等待/死锁检测
  - 自增序列锁
  - 半一致读
  - 隐式锁
- InnoDB多版本
  - ReadView
  - 聚簇索引/二级索引
  - 快照读
  - Index Only Scan
  - RC vs RR
  - Purge
- InnoDB事务/锁/多版本总结

InnoDB多版本

- InnoDB多版本定义

  一条语句，能够看到(快照读)本语句开始时(RC)/本事务开始时(RR)已经提交的其他事务所做的修改

  - 快照读
    - 读记录历史版本，而非当前更新未提交版本
    - 无需加锁，lock free
    - 语句级(RC)：语句开始时的快照
      - 语句级ReadView
    - 事务级(RR)：事务开始时的快照
      - 事务级ReadView
  - 看到？
    - 已提交的Insert/Update后项，可见并返回
    - 已提交的Delete/Update前项，可见并略过

InnoDB多版本-ReadView

- ReadView

所谓ReadView，是一个事务的集合，这些事务在ReadView创建时是活跃的(未提交/回滚)

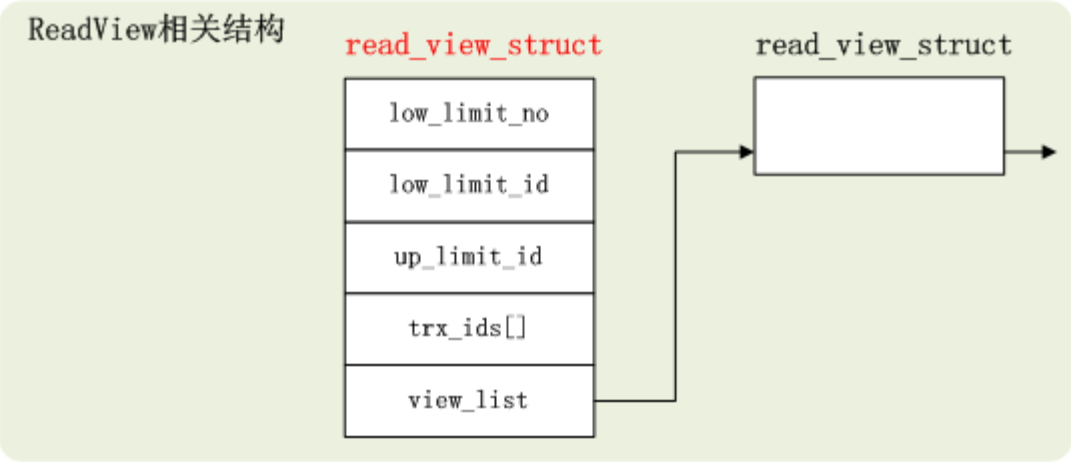

InnoDB多版本-ReadView(cont.)

- read_view_struct
  - **low_limit_no**
    - 提交时间早于此值(trx->no < low_limit_no)的事务，可以被purge线程回收
    - low_limit_no = trx_sys->max_trx_id
  - **low_limit_id**
    - >= 此值(trx->id >= low_limit_id)的事务，当前ReadView均不可见
    - low_limit_id = trx_sys->max_trx_id
  - **up_limit_id**
    - < 此值(trx->id < up_limit_id)的事务，当前ReadView一定可见
    - up_limit_id = ReadView创建时系统中最小活跃事务ID
  - **trx_ids[]**
    - 系统中所有活跃事务id组成的数组
- 创建ReadView
  - 获取kernel_mutex
    - 遍历trx_sys的trx_list链表，获取所有活跃事务，创建ReadView
  - Read Committed
    - 语句开始，创建ReadView
  - Repeatable Read
    - 事务开始，创建ReadView

InnoDB多版本-ReadView(cont.)

- ReadView创建

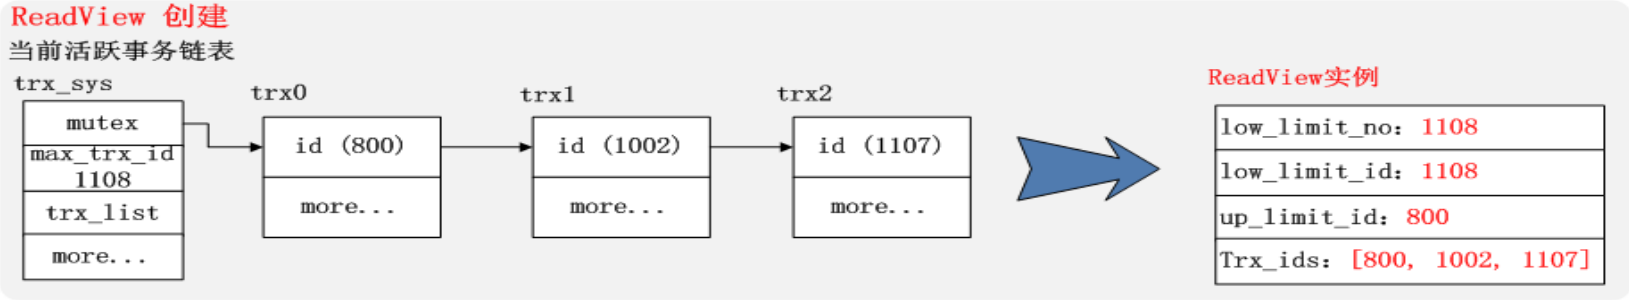

- RC VS RR

Read Committed

```
Begin;

Create ReadView1;

Statement 1;

Drop ReadView1;
Create ReadView2;

Statement 2;
...
Drop ReadView2;
Commit;
```

Repeatable Read

```
Begin;

Create ReadView1;

Statement 1;

Statement 2;

...

Drop ReadView1;
Commit;
```

InnoDB多版本-记录组织

- 聚簇索引记录
  - DB_TRX_ID
    - 生成此记录的事务ID
  - DB_ROLL_PTR
    - 此记录历史版本的指针
  - Delete_Bit(未给出)
- 二级索引记录
  - Delete_Bit
  - 索引页面，有DB_MAX_ID
    - 标识修改索引页面的最大事务ID

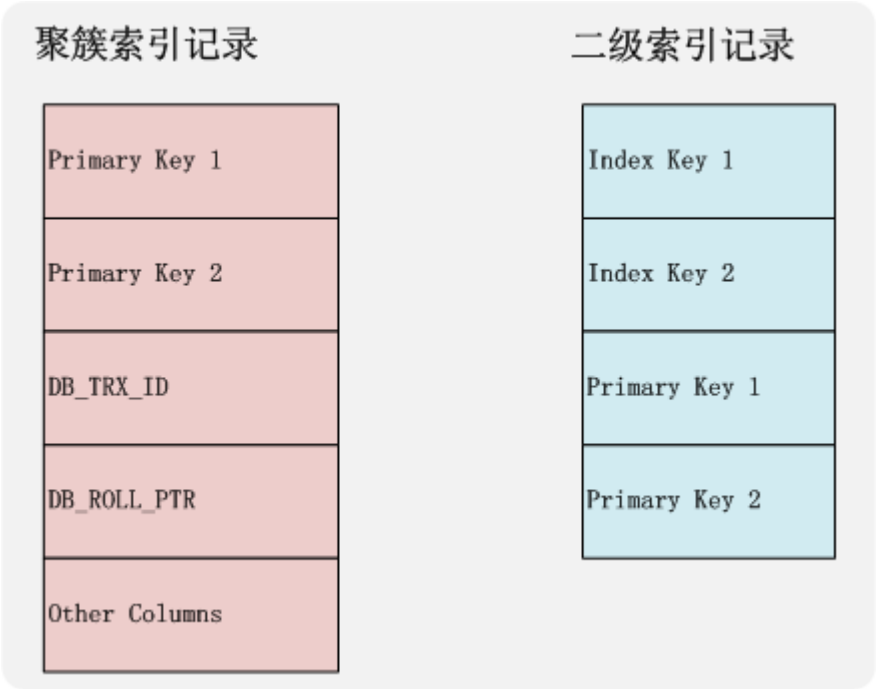

InnoDB多版本-更新

- 目的
  - 测试各种更新场景下，聚簇索引记录/二级索引记录的变化

- 准备

```
create table test (id int primary key, comment char(50)) engine=innodb;
create index test_idx on test(comment);

insert into test values (1, ‘aaa’);
insert into test values (2, ‘bbb’);
```

InnoDB多版本-更新(cont.)

- **更新主键**

  update test set id = 9 where id = 1;

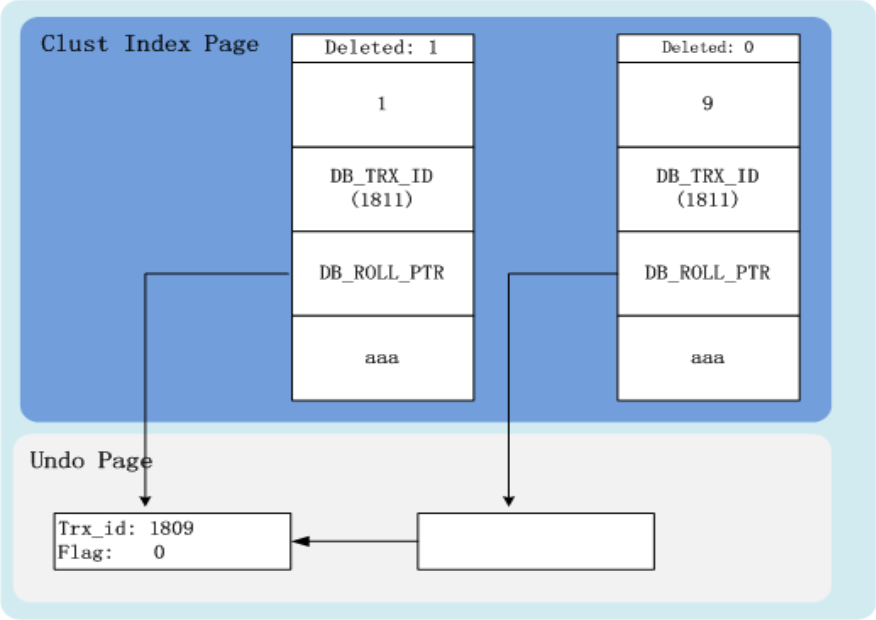

  - 旧记录标识为删除
  - 插入一条新纪录
  - 新旧记录前项均进入回滚段

InnoDB多版本-更新(cont.)

- 更新非主键

  update test set comment = ‘ccc’ where id = 9;

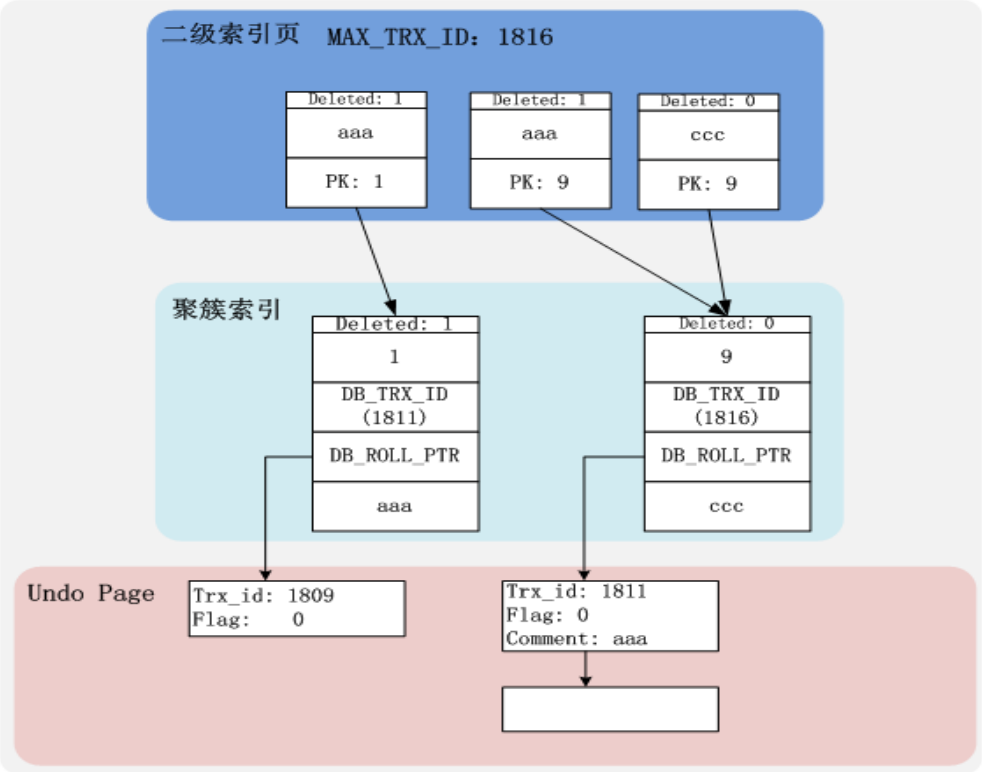

InnoDB多版本-更新(cont.)

- **InnoDB更新总结**
  - 更新主键，聚簇索引/二级索引均无法进行in place update，均会产生两个版本
  - 更新非主键，聚簇索引可以in place update；二级索引产生两个版本
  - 聚簇索引记录undo，二级索引不记录undo
  - 更新聚簇索引，记录旧版本会进入Rollback Segment Undo Page
  - 更新二级索引，同时需要判断是否修改索引页面的MAX_TRX_ID
  - 属于同一事务的undo记录，在undo page中保存逆向指针

InnoDB多版本-可见性

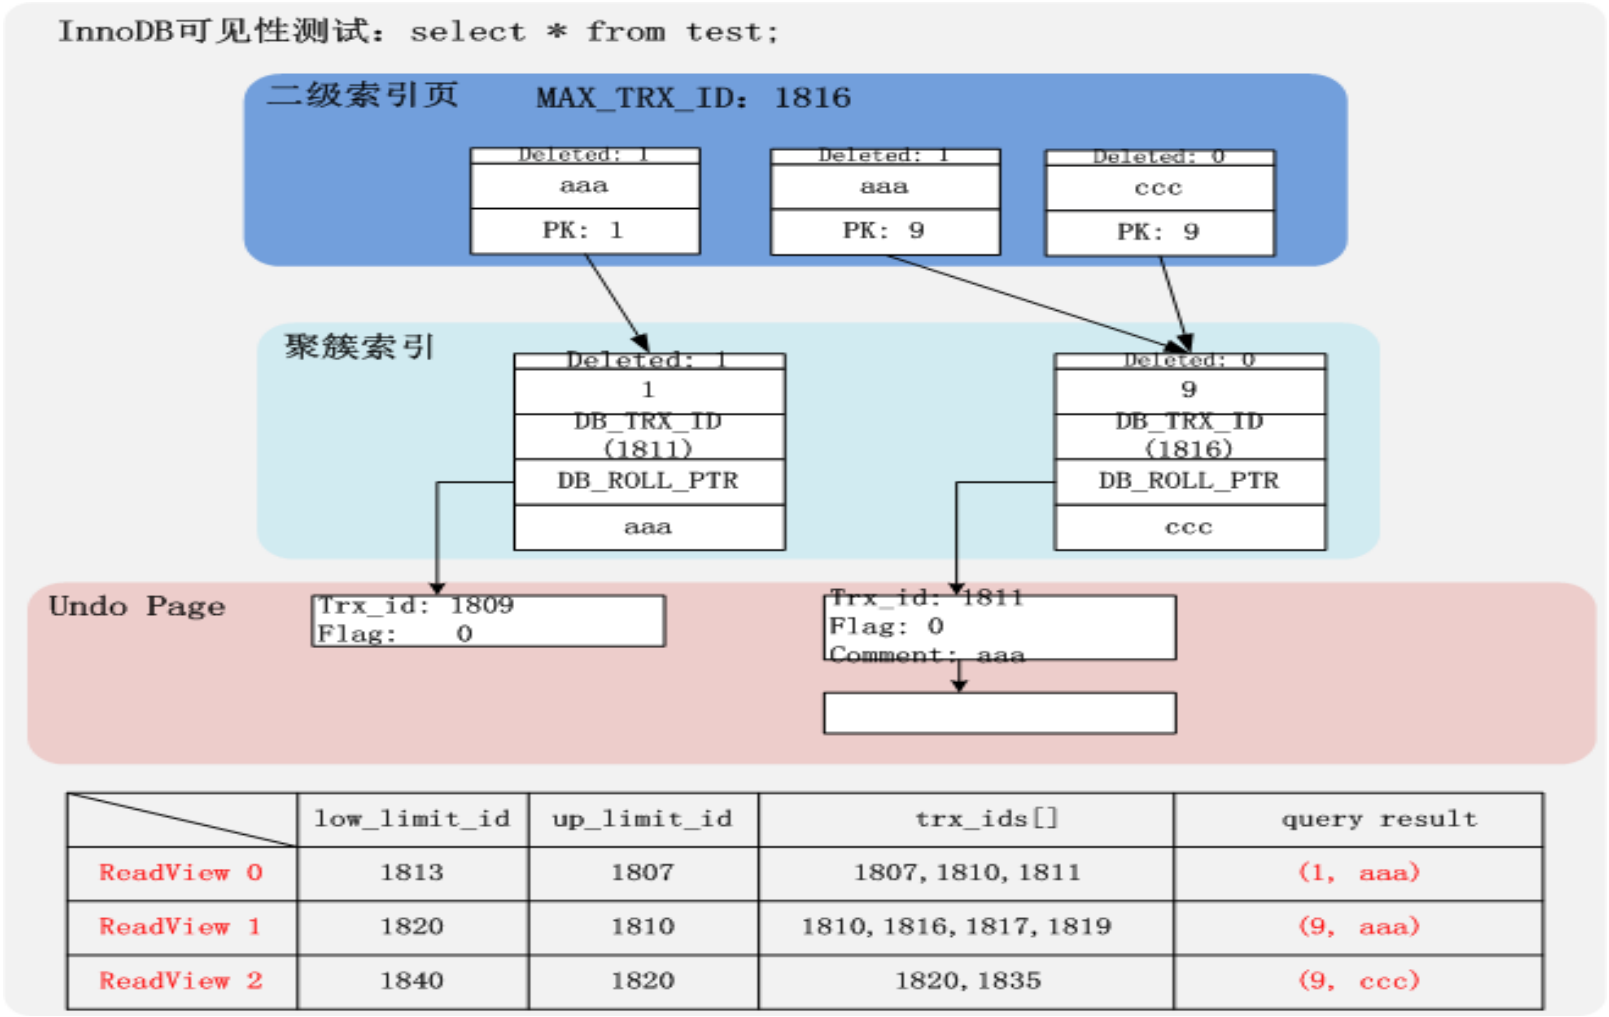

	low_limit_id	up_limit_id	trx_ids[]	query result
ReadView 0	1813	1807	1807, 1810, 1811	(1, aaa)
ReadView 1	1820	1810	1810, 1816, 1817, 1819	(9, aaa)
ReadView 2	1840	1820	1820, 1835	(9, ccc)

InnoDB多版本-Cluster Index Scan

- 聚簇索引扫描
  - 当前读
    - 加锁；读取记录最新版本
    - 通过记录的DB_TRX_ID判断是否存在Implicit lock
  - 快照读
    - 不加锁；
    - 根据ReadView读取可见版本
  - Index Only Scan
    - 一定为Index Only Scan

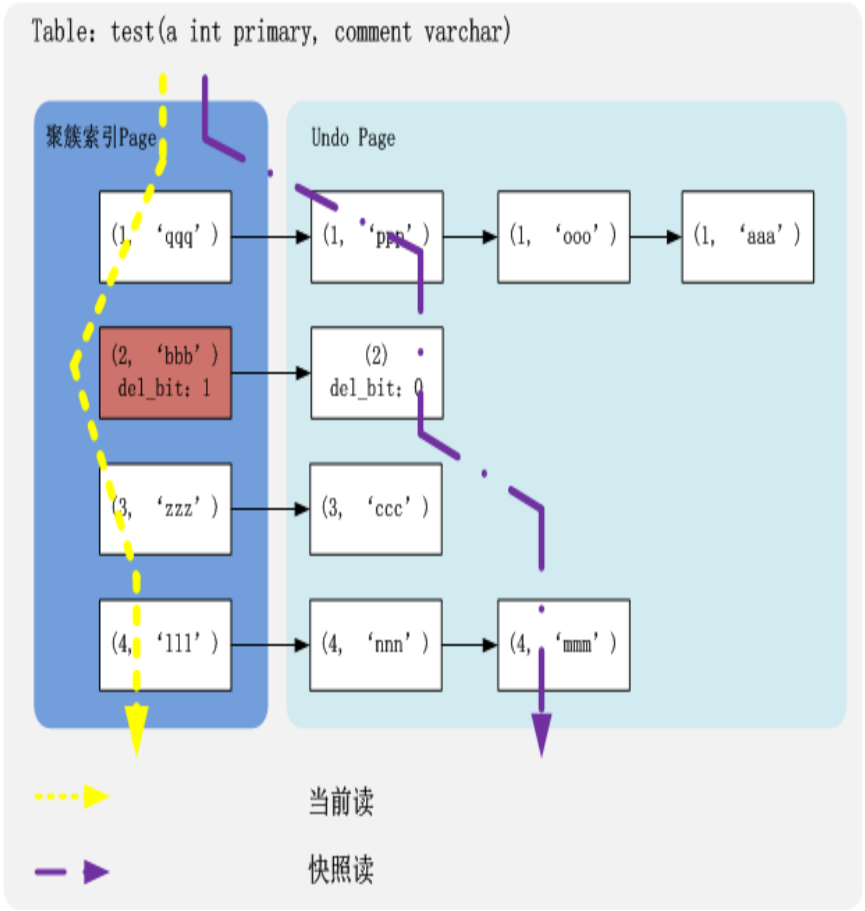

InnoDB多版本-Sec Index Scan

- 二级索引扫描
  - 当前读
    - 加锁(二级索引/聚簇索引)
    - 读取记录最新版本
    - 通过page上的MAX_TRX_ID判断是否可能存在Implicit lock
  - 快照读
    - 不加锁
    - 读取记录唯一可见版本
      - *如何过滤同一记录的不同版本？*
  - Index Only Scan
    - cont.

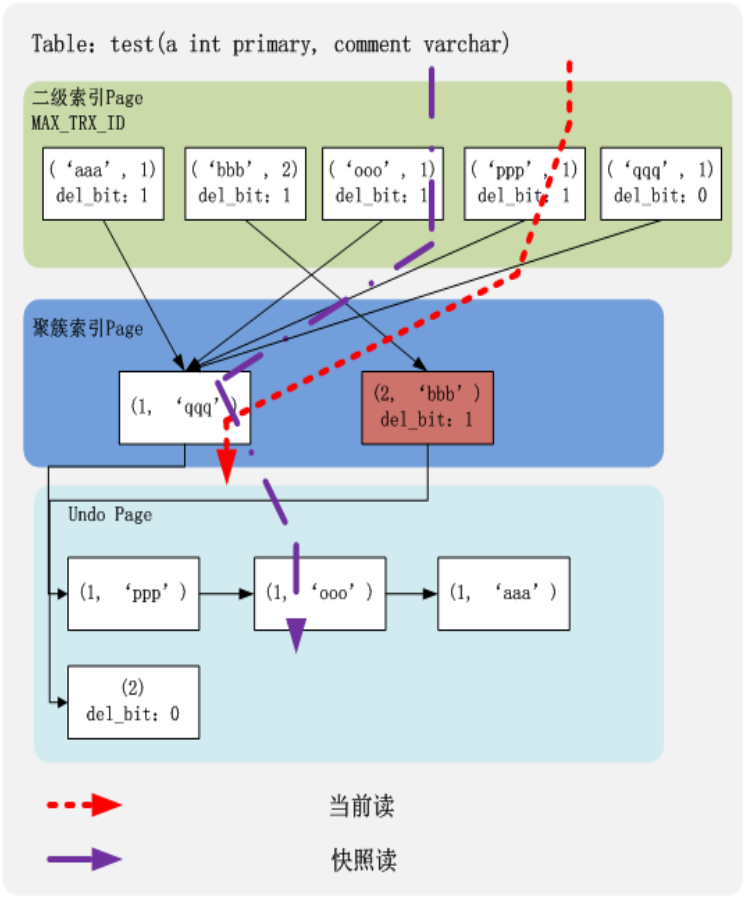

InnoDB多版本-Sec Index Scan(cont.)

- Index Only Scan
  - 当前读
    - 不能进行Index Only Scan
      - 当前读需要对聚簇索引记录加锁
      - 当前读需要访问聚簇索引，读取记录所有列
  - 快照读
    - 访问索引不存在的列
      - 不能进Index Only Scan
    - 仅仅访问索引列
      - 二级索引page的MAX_TRX_ID不可见 -> 不能进行Index Only Scan
        - » 此概率较小
      - MAX_TRX_ID可见 -> 可进行Index Only Scan
        - » **此概率极大**

InnoDB多版本-实例讲解

- MySQL Bugs 65745

  UPDATE on InnoDB table enters recursion,

  eats all disk space

- 重现脚本

```
DROP TABLE IF EXISTS t1;
CREATE TABLE t1 (
  id1 int NOT NULL,
  id2 int NOT NULL,
  a int,
  b int,
  PRIMARY KEY (id1,id2),
  KEY (id1, a)
) ENGINE=InnoDB DEFAULT CHARSET=utf8;

INSERT INTO `t1` VALUES (1,1,NULL,1);
INSERT INTO `t1` VALUES (2,2,1,NULL);
INSERT INTO `t1` VALUES (2,3,2,NULL);
INSERT INTO `t1` VALUES (2,4,3,NULL);
INSERT INTO `t1` VALUES (2,5,4,NULL);
INSERT INTO `t1` VALUES (2,6,NULL,2);

UPDATE t1 SET id2 = id2 + 1, b = null WHERE a is null and id1 = 2;
```

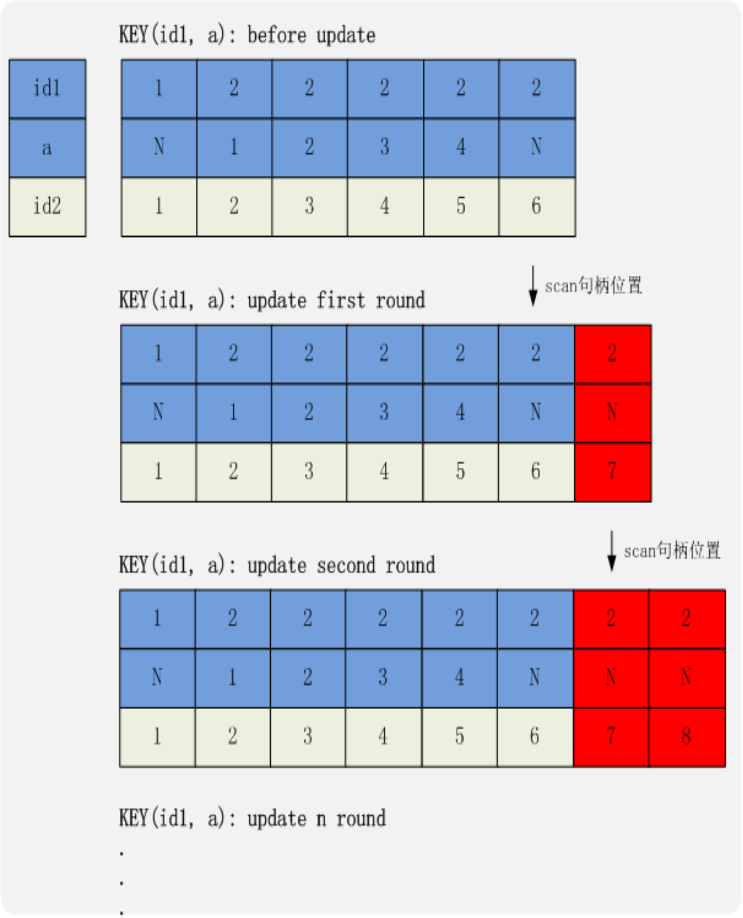

- 原因分析
  - 更新主键字段，二级索引同样会产生Halloween问题

InnoDB多版本-Purge

- Purge
  - 功能
    - 回收索引页面中被删除
      且不会被其他事务看到的项
  - 实现流程
    - 拷贝trx_sys ReadView链表中最老
      的read_view，作为purge_read_view
    - 遍历InnoDB系统中所有的Rollback Segment，
      取出最老的提交事务
    - 若purge_read_view.low_limit_no > old_trx.no；
      说明对应的事务可以被purge
    - 反向遍历事务的undo日志，
      构造索引记录，查询并删除
  - 参数/优化
    - innodb_max_purge_lag ()
    - innodb_purge_threads (since MySQL 5.6.2)

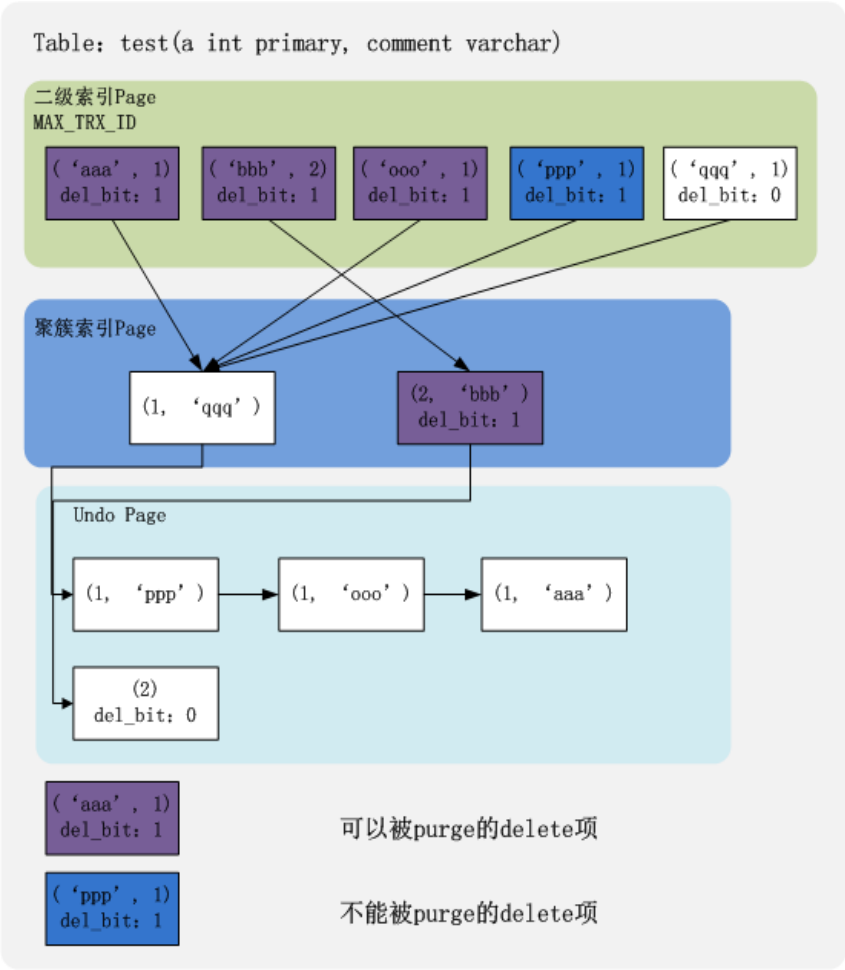

InnoDB事务/锁/多版本

- InnoDB事务
  - 事务结构/功能
  - XA事务
  - mini-transaction
- InnoDB锁
  - 锁结构/类型/功能
  - 锁等待/死锁检测
  - 自增序列锁
  - 半一致读
  - 隐式锁
- InnoDB多版本
  - ReadView
  - 聚簇索引/二级索引
  - 快照读
  - Index Only Scan
  - RC vs RR
  - Purge
- InnoDB事务/锁/多版本总结

InnoDB事务/锁/多版本-总结

- **RR vs RC**
  - Read Committed
    - 优势
      - 高并发，低锁开销：semi-consistent read
      - no gap lock；early unlock
    - 劣势
      - 不支持statement binlog
      - 语句级快照读：每条语句，新建ReadView
  - Repeatable Read
    - 优势
      - 支持gap lock；statement binlog
      - 事务级快照读：一个事务，对应一个ReadView
    - 劣势
      - 并发冲突高，加锁冲突更为剧烈
      - 不支持semi-consistent read；不支持early unlock

InnoDB事务/锁/多版本-总结(cont.)

- 事务Commit流程
  - prepare
    - 将redo日志从log buffer写入log file，并flush
      - innodb_flush_log_at_trx_commit
  - commit
    - 处理事务产生的undo pages
      - insert undo pages直接回收
      - 获取事务的trx->no (标识提交顺序)
      - update undo pages链入history list，等待purge
    - 释放事务持有的锁
      - 唤醒必要的等待者
    - 关闭事务的read_view
    - 将redo日志写出，并flush
      - innodb_flush_log_at_trx_commit

InnoDB事务/锁/多版本-总结(cont.)

- 事务Rollback流程
  - 反向遍历undo日志并应用
    - undo操作需要记录redo (undo的补偿日志)
  - 以下流程，与commit一致
    - 处理事务产生的undo pages
    - 释放事务锁
    - 关闭read_view
    - 将redo日志写出，并flush

InnoDB事务/锁/多版本-参考资料

- *Peter Zaitsev* InnoDB Architecture and Internals
- *MySQL Manual* InnoDB Startup Options and System Variables
- *Transactions on InnoDB* Better scaling of read-only workloads
- *Dimitrik* MySQL Performance: Read-Only Adventure in MySQL 5.6
- *Marco Tusa* Some fun around history list
- *MySQL Musings* Binlog Log Group Commit in MySQL 5.6
- *Kristian Nielsen* Even faster group commit!
- *MySQL Bugs* UPDATE on InnoDB table enters recursion, eats all disk space
- *sleebin9* MySQL数据库InnoDB存储引擎中的锁机制
- *何登成* InnoDB Crash Recovery & Rollback Segment源码实现分析
- *何登成* MySQL外部XA及其在分布式事务中的应用分析
- *何登成* MySQL InnoDB源代码调试跟踪分析
- *何登成* InnoDB SMO-Row-Page-Extent-Lock-Latch实现分析
- *何登成* MySQL+InnoDB semi-consitent read原理及实现分析
- *何登成* InnoDB多版本可见性分析
- *何登成* MariaDB & Percona XtraDB Group Commit实现简要分析
- *何登成* MVCC (Oracle, Innodb, Postgres)分析
- *何登成* MySQL Bug 65745分析

Q & A

谢谢大家！